

Ana Julia Vieira Lidório · Lara da Rosa Dondossola · Maine Calabrezi de Souza

MACHINE LEARNING · UNISATC

Análise e Predição de Eventos Climáticos Extremos

*Estimando a população afetada por desastres climáticos com modelos de regressão de
Machine Learning*

Por que estimar o impacto de desastres climáticos?

Gargalos Atuais

- Hoje, os dados de desastres já são registrados em **sistemas oficiais** (S2iD, Atlas Digital), mas cruzar informações e identificar padrões entre eventos e seus impactos é uma tarefa complexa.

Importância atual

- Fenômenos como o El Niño alteram padrões de chuva e temperatura, intensificando **fenômenos extremos** no Brasil e afetando milhares de pessoas.

CASO REAL — RIO GRANDE DO SUL, 2024

2,4 milhões

de pessoas afetadas pelas enchentes

478 de 497 municípios atingidos

183 óbitos registrados

121.878 pessoas desabrigadas

834.645 pessoas desalojadas

Danos Informados - S2iD

- **Fonte:** Sistema Integrado de Informações sobre Desastres (S2iD), do Ministério da Integração e do Desenvolvimento Regional.
- **Recorte:** todos os registros de desastres ocorridos no Brasil em 2024, cobrindo todos os estados.
- **53 variáveis originais:** dados humanos (mortos, feridos, desabrigados...), danos materiais, prejuízos econômicos públicos e privados e variáveis ambientais.

Antes da modelagem, o dataset passou por uma **etapa proposital de inserção de ruídos** (nulos, duplicatas, inconsistências) para simular um cenário real de dados e validar o pipeline de limpeza.

6.036

registros de desastres

53

variáveis originais

27

estados brasileiros

2024

ano de referência

Por que o tema importa na prática

Estimativa de impacto

- Projeção do volume de pessoas afetadas.
- Apoia decisões preventivas e de resposta ao desastre.
- Oferece um diagnóstico rápido logo após os primeiros registros da crise.

Eficiência de recursos

- Ajuda a Defesa Civil a otimizar planejamento e logística.
- Permite dimensionar equipes, abrigos e insumos com mais precisão.
- Contribui para reduzir os danos à população.

Relevância do ML

- Conecta variáveis climáticas e históricas para achar padrões.
- Gera estimativas para novos desastres à medida que ocorrem.
- Troca verificações manuais por análise preditiva rigorosa.

Como o problema foi modelado tecnicamente

1. Tipo de abordagem

- Aprendizado Supervisionado — Regressão.

2. Variável alvo (target)

- **Coluna alvo:** População_Afetada_Total — soma dos danos humanos (mortos, feridos, desabrigados, desalojados).
- O Nível de Risco (Baixo/Médio/Alto) não é um segundo modelo treinado: é derivado matematicamente da própria previsão de regressão.

3. Dataset escolhido

- Fonte: Relatório Gerencial “Danos Informados”, do S2iD (Sistema Integrado de Informações sobre Desastres).
- Atributos: dados por município, código COBRADE, danos humanos, materiais e prejuízos econômicos.



POR QUE ISSO IMPORTA

Cada casa, plantação ou família por trás desses números depende de uma resposta rápida e bem direcionada da Defesa Civil.

Conceitos-chave e o cenário de desastres no Brasil

Conceitos-chave

- **Eventos extremos:** fenômenos atmosféricos e hidrológicos mapeados pelo sistema COBRADE no Brasil.
- **Danos e impacto humano:** divisão entre danos humanos (afetados, desalojados etc.), materiais e prejuízos econômicos.
- **Risco de desastre:** interação entre ameaça natural, exposição e vulnerabilidade populacional.

Estatísticas & fatos (S2iD / Atlas Digital)

- Mais de **60 mil desastres** registrados no país nas últimas três décadas.
- **Eventos críticos:** alto impacto de inundações no RS, enxurradas e movimentos de massa.
- O **El Niño** aumenta significativamente a probabilidade de chuvas intensas na região Sul.

Por que ir além das soluções não-ML existentes

Abordagem atual

- Previsões do tempo, mapas de risco e monitoramento contínuo (CEMADEN, INMET, Defesa Civil).

Limitação

- Dificuldade em processar grandes volumes de dados históricos para estimar, de forma numérica, a população afetada por um evento específico.

Gargalo

- Baixa capacidade das abordagens tradicionais de identificar padrões complexos e não lineares entre variáveis ambientais, sociais e de infraestrutura.

É exatamente essa lacuna — transformar dados históricos em estimativas numéricas — que o Machine Learning se propõe a preencher neste projeto.

O estado da arte - artigos relacionados ao estudo

Estudos aplicam ML a problemas muito parecidos com o nosso — prever o impacto humano e econômico de eventos climáticos — e reforçam por que o Random Forest se destaca nesse tipo de dado.

2022 · INT. J. DISASTER RISK REDUCTION

Interpretable data-driven model for Climate-Induced Disaster damage prediction

O quê: modelo preditivo de danos de vendaval, combinando clima, características do desastre, uso do solo, condições sociais, habitação, demografia e economia (Nova York, 2010–2018).

Resultado: entre os modelos testados, o Random Forest foi o de melhor desempenho, com R^2 (coeficiente de determinação) = 0,79.

*Conecta direto com o nosso projeto: **também trabalha com danos humanos**, materiais e prejuízos econômicos como variáveis de entrada.*

2024 · INT. J. DISASTER RISK REDUCTION

Predictive modeling of severe weather impact on individuals and populations using ML

O quê: prevê o nível de incidentes causados por clima severo em 947 municípios da Catalunha (Espanha, 2015–2021), a partir de dados meteorológicos e características do município.

Resultado: o Random Forest Classifier teve a maior acurácia entre os modelos comparados — 0,84 de início, 0,87 após ajuste de hiperparâmetros.


*Os autores **destacam a robustez do RF a dados não lineares e sua capacidade de lidar com classes desbalanceadas** — exatamente o cenário do nosso dataset.*

06 · METODOLOGIA

Da coleta de dados ao modelo treinado



Etapas do projeto



Preparação dos dados e engenharia de atributos

1. Variável alvo (regressão):

- **População_Afetada_Total** — soma de mortos, feridos, enfermos, desabrigados, desalojados, desaparecidos e outros afetados.

2. Remoção de vazamento de dados (data leakage):

- as colunas que compõem o alvo e identificadores (Registro, Protocolo, Município) são excluídas das features.

3. Novas variáveis criadas:

- Total_Estruturas_Danificadas/Destruídas
- Tipo_Evento (extraído do código COBRADE)
- Log_Populacao.

PIPELINE DE TRANSFORMAÇÃO (scikit-learn)

ROBUSTSCALER

variáveis numéricas — robusto a outliers extremos

OneHotEncoder

variáveis categóricas (UF, Tipo_Evento...)

ColumnTransformer

combina os dois passos acima em um único objeto

train_test_split

70% treino / 30% teste, random_state=42

Três modelos de regressão comparados

1

BASELINE

Regressão Linear

Estabelece uma relação direta entre as variáveis de entrada e a população afetada, assumindo que o efeito de cada fator é proporcional. Por ser o modelo mais simples, funciona como referência inicial para comparação com os demais.

2

BASEADO EM VIZINHANÇA

KNN Regressor Ponderado

Estima o resultado com base nos k vizinhos mais próximos — ou seja, os eventos históricos mais parecidos com o caso analisado — calculando uma média ponderada entre eles. Quanto mais próximo (similar) o vizinho, maior seu peso na previsão.

3

ENSEMBLE DE ÁRVORES

Random Forest Regressor

Combina os resultados de diversas árvores de decisão, cada uma treinada com uma amostra distinta dos dados. Essa combinação torna o modelo mais robusto e capaz de identificar padrões mais complexos, por isso se torna a melhor escolha para esse tema.

Por que treinar em escala logarítmica?

- A **população afetada** é **extremamente assimétrica**: a maioria dos eventos afeta poucas pessoas, mas alguns (ex.: Brasília, ~2,98 milhões) são **outliers extremos**.
- Antes de treinar, aplicamos $y_{\log} = \text{np.log1p}(\text{população_afetada})$, o que comprime a escala e reduz a influência desproporcional desses eventos gigantes sobre o erro do modelo.
- Os três modelos treinam e preveem em escala log; ao final, a previsão é convertida de volta com $\text{np.expm1}()$ para virar uma estimativa em número de pessoas.
- Sem essa transformação, **o erro de poucos desastres extremos dominaria a métrica e mascararia o desempenho do modelo** no restante dos dados.

$$y_{\log} = \log(1 + y)$$

Treino do modelo na escala log

$$\text{previsão_final} = \exp(\text{previsão_log}) - 1$$

Conversão de volta para nº de pessoas


Validação cruzada com GridSearchCV

O KNN e o Random Forest foram otimizados com GridSearchCV (cv=5): os dados de treino são divididos em 5 partes (folds); **a cada rodada, o modelo treina em 4 e valida na 5ª, alternando qual parte fica de fora.**

Isso testa cada combinação de hiperparâmetros de forma mais confiável do que uma única divisão treino/validação, **reduzindo o risco de overfitting** no ajuste.


- Métrica de otimização: R^2 médio entre as 5 dobras.

COMO FUNCIONA (cv = 5)



O que é o Random Forest?

- Em vez de treinar e confiar em apenas uma única árvore de decisão, o **Random Forest cria várias árvores diferentes** e combina as respostas.
- Bagging (Bootstrap Aggregating): cada árvore aprende com uma amostra aleatória e um pouco diferente dos dados de treino, **como se cada uma tivesse visto uma versão levemente distinta da realidade**.
- Feature subsampling: em cada divisão da árvore, apenas um subconjunto aleatório das variáveis é considerado (`max_features='sqrt'`).
- É como perguntar a opinião de várias pessoas ao invés de confiar em uma só: **o erro de uma árvore tende a ser compensado pelas outras**. No fim, a previsão final do modelo é a média das previsões de todas as árvores da floresta.



cada árvore vota uma previsão

Por que o Random Forest foi o melhor modelo para este tema

1 Maior R^2

$R^2 = 0,7591$ — o mais alto entre os três modelos testados, mesmo com dados ruidosos e não-lineares.

2 Relações não-lineares

Consegue capturar combinações complexas entre variáveis ambientais, populacionais e de infraestrutura que outros modelos não enxergam.

3 Robustez a outliers

Dividir os dados em várias árvores reduz o peso de eventos extremos isolados sobre o modelo final.

4 Interpretabilidade via Feature Importance

Permite identificar quais variáveis mais influenciam a população afetada — algo que o KNN não oferece.

12 · RESULTADOS

O que os números mostraram



As métricas mudaram pouco após a otimização

ANTES


	Modelo de Regressão	MAE (Pessoas)	RMSE (Pessoas)	R ² (Escala Log)
0	Regressão Múltipla	32127.61	236709.60	0.5324
1	KNN Regressor (K=15)	8426.04	85732.99	0.6739
2	Random Forest Regressor	7940.55	70134.26	0.7592

DEPOIS

	Modelo de Regressão	MAE (Pessoas)	RMSE (Pessoas)	R ² (Escala Log)
0	Regressão Múltipla	30861.52	227150.82	0.5130
1	KNN Regressor (K=15)	7660.81	65692.43	0.6750
2	Random Forest Regressor	9686.21	94839.79	0.7591

- GridSearchCV trouxe ganhos pequenos: o Random Forest já performava bem com hiperparâmetros padrão e não teve tanta melhora com a otimização.
- Isso indica que o pré-processamento e a feature engineering pesaram mais no resultado final do que o ajuste fino dos hiperparâmetros.


Previsto vs. Real



Quanto mais próximos os pontos ficam da linha tracejada, melhor a previsão. O Random Forest concentra os pontos mais próximos da diagonal; a Regressão é a que mais dispersa.

O que mais influencia a população afetada?

- Variáveis ligadas a **exaurimento hídrico e abastecimento de água** aparecem entre as mais importantes.
- Gastos públicos com **agricultura e pecuária** também pesam bastante na previsão.
- A **própria população do município** (e sua versão em log) é, como esperado, altamente relevante.
- O estado do **Rio Grande do Sul (UF_RS)** se destaca — reflexo do peso das enchentes de 2024 na base.



Como definimos o Nível de Risco - Classificação

O Nível de Risco (Baixo / Médio / Alto) não vem de um modelo de classificação treinado à parte.

Ele é calculado em cima da própria previsão de regressão: pegamos a população afetada estimada e calculamos que **porcentagem ela representa da população total do município**.

- **Definição dos cortes:**

Para cada desastre, **calculamos a porcentagem da população do município afetada**. A distribuição desse indicador na base histórica foi analisada e foram adotados **dois pontos de corte**, próximos à **mediana** (3,6034%) e ao **3º quartil/P75** (50,1603%). Esses valores transformam a previsão numérica da regressão em três categorias: Baixo, Médio e Alto risco.

CRITÉRIO DE CLASSIFICAÇÃO

% da população do município que foi afetada

- **Baixo** até 3,6034%
- **Médio** de 3,6034% até 50,16%
- **Alto** acima de 50,16%


EXEMPLO PRÁTICO

Valor real do dataset: **10% da população afetada** → **Risco Médio**

Previsão do Random Forest: **3% da população afetada** → **Risco Baixo**

Nesse caso o modelo subestimou o risco — um dos motivos da confusão entre Médio e Baixo na matriz da próxima página.

Nível de risco - Classificação



EXEMPLO PRÁTICO

Valor real do dataset: **10% da população afetada → Risco Médio**

Previsão do Random Forest: **3% da população afetada → Risco Baixo**

Nesse caso o modelo subestimou o risco — um dos motivos da confusão entre Médio e Baixo na matriz da próxima página.

Convertendo a previsão de regressão em categoria de risco (Baixo/Médio/Alto), o Random Forest acerta bem os riscos Baixo e Médio; a maior confusão está no risco Alto.

CONCLUSÃO

Random Forest é o modelo mais adequado para estimar a população afetada por desastres climáticos

- Melhor equilíbrio entre erro (MAE/RMSE) e capacidade de generalização (R^2) entre os 3 modelos testados.
- Transformação logarítmica do alvo e feature engineering foram tão decisivas quanto a escolha do algoritmo.
- Validação cruzada (GridSearchCV, cv=5) confirmou a estabilidade dos resultados, sem overfitting aparente.