


06 · METODOLOGIA

Da coleta de dados ao modelo treinado



Etapas do projeto



Preparação dos dados e engenharia de atributos

1. Variável alvo (regressão):

- **População_Afetada_Total** — soma de mortos, feridos, enfermos, desabrigados, desalojados, desaparecidos e outros afetados.

2. Remoção de vazamento de dados (data leakage):

- as colunas que compõem o alvo e identificadores (Registro, Protocolo, Município) são excluídas das features.

3. Novas variáveis criadas:

- Total_Estruturas_Danificadas/Destruídas
- Tipo_Evento (extraído do código COBRADE)
- Log_Populacao.

PIPELINE DE TRANSFORMAÇÃO (scikit-learn)

ROBUSTSCALER

variáveis numéricas — robusto a outliers extremos

OneHotEncoder

variáveis categóricas (UF, Tipo_Evento...)

ColumnTransformer

combina os dois passos acima em um único objeto

train_test_split

70% treino / 30% teste, random_state=42

Três modelos de regressão comparados

1

BASELINE

Regressão Linear

Estabelece uma relação direta entre as variáveis de entrada e a população afetada, assumindo que o efeito de cada fator é proporcional. Por ser o modelo mais simples, funciona como referência inicial para comparação com os demais.

2

BASEADO EM VIZINHANÇA

KNN Regressor

Estima o resultado com base nos k vizinhos mais próximos — ou seja, os eventos históricos mais parecidos com o caso analisado — calculando uma média ponderada entre eles. Quanto mais próximo (similar) o vizinho, maior seu peso na previsão.

3

ENSEMBLE DE ÁRVORES

Random Forest Regressor

Combina os resultados de diversas árvores de decisão, cada uma treinada com uma amostra distinta dos dados. Essa combinação torna o modelo mais robusto e capaz de identificar padrões mais complexos, por isso se torna a melhor escolha para esse tema.

Por que treinar em escala logarítmica?

- A **população afetada** é **extremamente assimétrica**: a maioria dos eventos afeta poucas pessoas, mas alguns (ex.: Brasília, ~2,98 milhões) são **outliers extremos**.
- Antes de treinar, aplicamos $y_{\log} = \text{np.log1p}(\text{população_afetada})$, o que comprime a escala e reduz a influência desproporcional desses eventos gigantes sobre o erro do modelo.
- Os três modelos treinam e preveem em escala log; ao final, a previsão é convertida de volta com $\text{np.expm1}()$ para virar uma estimativa em número de pessoas.
- Sem essa transformação, **o erro de poucos desastres extremos dominaria a métrica e mascararia o desempenho do modelo** no restante dos dados.

$$y_{\log} = \log(1 + y)$$

Treino do modelo na escala log

$$\text{previsão_final} = \exp(\text{previsão_log}) - 1$$

Conversão de volta para nº de pessoas


Validação cruzada com GridSearchCV

O KNN e o Random Forest foram otimizados com GridSearchCV (cv=5): os dados de treino são divididos em 5 partes (folds); **a cada rodada, o modelo treina em 4 e valida na 5ª, alternando qual parte fica de fora.**

Isso testa cada combinação de hiperparâmetros de forma mais confiável do que uma única divisão treino/validação, **reduzindo o risco de overfitting** no ajuste.


- Métrica de otimização: R^2 médio entre as 5 dobras.

COMO FUNCIONA (cv = 5)



O que é o Random Forest?

- Em vez de treinar e confiar em apenas uma única árvore de decisão, o **Random Forest cria várias árvores diferentes** e combina as respostas.
- Bagging (Bootstrap Aggregating): cada árvore aprende com uma amostra aleatória e um pouco diferente dos dados de treino, **como se cada uma tivesse visto uma versão levemente distinta da realidade**.
- Feature subsampling: em cada divisão da árvore, apenas um subconjunto aleatório das variáveis é considerado (`max_features='sqrt'`).
- É como perguntar a opinião de várias pessoas ao invés de confiar em uma só: **o erro de uma árvore tende a ser compensado pelas outras**. No fim, a previsão final do modelo é a média das previsões de todas as árvores da floresta.



cada árvore vota uma previsão

Por que o Random Forest foi o melhor modelo para este tema

1 Maior R^2

$R^2 = 0,7591$ — o mais alto entre os três modelos testados, mesmo com dados ruidosos e não-lineares.

2 Relações não-lineares

Consegue capturar combinações complexas entre variáveis ambientais, populacionais e de infraestrutura que outros modelos não enxergam.

3 Robustez a outliers

Dividir os dados em várias árvores reduz o peso de eventos extremos isolados sobre o modelo final.

4 Interpretabilidade via Feature Importance

Permite identificar quais variáveis mais influenciam a população afetada — algo que o KNN não oferece.