

CENTRO UNIVERSITÁRIO SATC - UNISATC
ENGENHARIA DE COMPUTAÇÃO

ANA JULIA VIEIRA LIDÓRIO
LARA DA ROSA DONDOSSOLA
MAINE CALABREZI DE SOUZA

ANÁLISE E PREDIÇÃO DOS EVENTOS CLIMÁTICOS

CRICIÚMA
2026

SUMÁRIO

1. INTRODUÇÃO	3
2. CONTEXTUALIZAÇÃO	4
2.1. Domínio da aplicação	4
2.2. Situação atual	4
2.3. Base teórica	4
3. DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING	5
3.1. Definição técnica	5
3.2. Variável alvo	5
3.3. Dataset	5
4. JUSTIFICATIVA E RELEVÂNCIA	6
5. OBJETIVOS	6
5.1. Objetivo geral	6
5.2. Objetivos específicos	6
6. FUNDAMENTAÇÃO TEÓRICA	7
6.1. Conceitos chaves do domínio	7
6.2. Estatísticas e fatos	7
6.3. Soluções não-ml existentes	8
7. METODOLOGIA E DESENVOLVIMENTO	8
7.1. Modelos	8
7.2. Análise exploratória de dados (EDA)	9
7.3. Pré-processamento e Feature Engineering	11
7.4. Implementação, treinamento e otimização dos modelos	12
7.5. Avaliação e análise de resultados	13
8. INTERFACE	19
9. GITHUB	20
10. CONCLUSÃO	21
11. REFERÊNCIAS	22

1. INTRODUÇÃO

O Brasil, devido à sua vasta extensão territorial e diversidade climática, enfrenta recorrentemente os impactos severos de eventos meteorológicos e hidrológicos extremos. Fenômenos como chuvas intensas, inundações, enxurradas e secas prolongadas afetam diretamente milhares de municípios todos os anos, provocando perdas humanas, danos materiais a infraestruturas e profundos prejuízos socioeconômicos. Nesse cenário, a atuação da Defesa Civil e dos órgãos governamentais de gestão de riscos torna-se indispensável, exigindo ações ágeis e coordenadas que abrangem desde a preparação e prevenção até a resposta imediata em situações de calamidade.

Historicamente, o registro e o acompanhamento dessas ocorrências no país são consolidados por meio de plataformas oficiais, como o Sistema Integrado de Informações sobre Desastres (S2iD). Embora esses repositórios acumulem um volume expressivo de dados históricos, a complexidade inerente aos desastres — cujos impactos variam drasticamente conforme a intensidade do evento, a vulnerabilidade do território e as características demográficas locais — dificulta a identificação manual de padrões. Abordagens estatísticas tradicionais e ferramentas descritivas, apesar de úteis para o mapeamento retrospectivo, apresentam limitações operacionais significativas quando o objetivo é antecipar de forma precisa a real dimensão dos danos e o número de pessoas afetadas.

Diante desse cenário, este trabalho propõe a aplicação de técnicas de Aprendizagem Automática (*Machine Learning*) para prever a população afetada e classificar o nível de risco de ocorrências registradas em 2024. Por meio de um pipeline estruturado de pré-processamento, engenharia de atributos e a avaliação comparativa entre os modelos Regressão Linear Múltipla, KNN e *Random Forest Regressor*, o estudo visa fornecer uma ferramenta computacional robusta para otimizar a tomada de decisão, o planejamento e a alocação de recursos em situações de calamidade.

2. CONTEXTUALIZAÇÃO

2.1. Domínio da aplicação

O problema está inserido no domínio de gestão de riscos e desastres, com foco na atuação da Defesa Civil. Essa área envolve o monitoramento, registro e análise de eventos que podem causar impactos à população, à infraestrutura e à economia. Nesse contexto, são utilizados dados históricos de desastres para compreender seus impactos e apoiar ações de prevenção, preparação e resposta.

2.2. Situação atual

A gestão de desastres envolve a coleta e análise de diversas informações sobre os eventos ocorridos, incluindo sua localização, características, danos causados e quantidade de pessoas afetadas. Atualmente, essas informações são registradas e posteriormente disponibilizadas em sistemas oficiais, como o S2iD, permitindo que gestores e pesquisadores consultem dados históricos sobre os desastres. Entretanto, a grande quantidade e variedade de informações existentes pode tornar a análise desses dados uma tarefa complexa, principalmente quando se busca identificar padrões entre diferentes eventos e seus impactos sobre a população. Além disso, desastres podem apresentar características bastante diferentes entre si, mesmo quando pertencem a uma mesma categoria. A intensidade do evento, a localização, as características da população e as condições do município podem influenciar diretamente a dimensão dos impactos observados.

2.3. Base teórica

No contexto atual das alterações climáticas, prevê-se que a frequência, a duração e a intensidade dos eventos meteorológicos extremos aumentem de forma significativa, intensificando os respectivos impactos nas populações, ecossistemas e infraestruturas. Perante este cenário, a literatura da especialidade destaca a necessidade urgente de transitar para estratégias proativas de preparação e resposta a desastres.

Investigações recentes, como o estudo desenvolvido por Iglesias et al. (2024), demonstram que a aplicação de técnicas de Aprendizagem Automática (*Machine Learning*) permite prever com elevada precisão o impacto de eventos meteorológicos extremos a nível municipal. No seu trabalho, os autores utilizaram dados desagregados de 947 municípios da região da Catalunha recolhidos ao longo de vários anos, combinando preditores acessíveis como dados meteorológicos diários (temperatura,

precipitação, velocidade do vento, altura de ondas e neve), informações demográficas, características geográficas e o uso do solo (densidade populacional, percentagem de áreas urbanas, agrícolas, florestais e de água). Com base nesses dados e no histórico de chamadas e incidentes registrados pelo centro de atendimento de emergências (112), a equipe desenvolveu e testou modelos preditivos — com destaque para o classificador *Random Forest* —, demonstrando que a abordagem computacional supera os sistemas tradicionais de alerta meteorológico baseados estritamente na previsão do estado do tempo. Além disso, os autores utilizaram o modelo para simular e avaliar de que forma alterações no uso do solo, como a expansão urbana sobre áreas florestais ou agrícolas, afetam a severidade e a quantidade de incidentes gerados por tempestades.

3. DEFINIÇÃO DO PROBLEMA EM MACHINE LEARNING

3.1. Definição técnica

O problema enquadra-se como um problema de Regressão Supervisada. O objetivo central é prever o valor numérico contínuo referente à população afetada total decorrente de ocorrências de desastres naturais.

3.2. Variável alvo

Regressão: A variável alvo principal é **População_Afetada_Total**, obtida diretamente pela soma agregada das colunas de danos humanos disponíveis no dataset (DH_Mortos, DH_Feridos, DH_Enfermos, DH_Desabrigados, DH_Desalojados, DH_Desaparecidos e DH_Outros Afetados).

Análise Categórica Derivada (Matriz de Confusão): Complementarmente, o código implementa uma função de categorização baseada em cortes percentuais sobre a população do município (**classificar_nivel_risco**) para traduzir as previsões contínuas em faixas de risco discretas (Baixo, Médio e Alto).

3.3. Dataset

O dataset utilizado foi obtido a partir do **Sistema Integrado de Informações sobre Desastres (S2iD)**, disponibilizado pelo **Ministério da Integração e do Desenvolvimento Regional**. A partir da base disponibilizada pelo S2iD, foi realizado um filtro considerando todos os registros de desastres ocorridos durante o ano de 2024, abrangendo todos os estados brasileiros.

A escolha dessa base é adequada ao problema proposto por utilizar dados reais e oficiais de ocorrências de desastres no Brasil, permitindo analisar seus impactos e utilizar essas informações para o desenvolvimento das abordagens de classificação e regressão propostas no trabalho.

4. JUSTIFICATIVA E RELEVÂNCIA

A solução desenvolvida traz benefícios práticos diretos para a gestão de riscos e para a atuação da Defesa Civil e órgãos governamentais, permitindo otimizar a logística e a alocação de recursos. Ao prever de forma precisa a população afetada total e classificar o nível de impacto do desastre, os gestores públicos conseguem antecipar a escala da ocorrência, direcionando suprimentos, abrigos e equipes de resgate de maneira rápida e eficiente para os municípios que necessitam. Além disso, essa estimativa antecipada atua na prevenção e na tomada de decisão ágil, reduzindo o tempo de resposta entre o evento climático extremo e o atendimento à população vulnerável.

O uso de Machine Learning é fundamental nesse contexto devido à complexidade e ao volume dos dados históricos. Diferentemente de abordagens baseadas exclusivamente em regras predefinidas ou planilhas manuais, os algoritmos de aprendizado de máquina — como os modelos de regressão e otimização implementados — são capazes de identificar padrões e relações não lineares complexas entre múltiplas variáveis ambientais e estruturais, garantindo maior capacidade de generalização e suporte robusto ao planejamento preditivo em larga escala.

5. OBJETIVOS

5.1. Objetivo Geral

Desenvolver e comparar modelos de Machine Learning Clássico para prever a população afetada e o nível de risco em eventos climáticos extremos, utilizando um conjunto de dados públicos de danos informados.

5.2. Objetivos Específicos

- a) Obter, inspecionar e estruturar o dataset real e pertinente ao problema.
- b) Realizar a Análise Exploratória de Dados (EDA) para diagnosticar a qualidade dos dados.
- c) Implementar o pipeline de Pré-processamento e Engenharia de Atributos (Feature Engineering).

- d) Treinar e otimizar, no mínimo, dois (2) modelos de Machine Learning Clássico para comparação.
- e) Comparar o desempenho dos modelos utilizando métricas adequadas e a base de testes.
- f) Analisar a contribuição dos atributos (Feature Importance), se for aplicável ao modelo escolhido.
- g) Desenvolver uma prototipagem simples de Deployment.

6. FUNDAMENTAÇÃO TEÓRICA

6.1. Conceitos chaves do domínio

- **Desastres:** Impactos de um evento adverso que causam danos, perdas e interrompem a rotina de uma comunidade, exigindo reconstrução.
- **Risco de desastre:** Probabilidade de danos pela junção de um evento adverso com a vulnerabilidade e exposição de um território.
- **Danos materiais:** Estragos físicos em infraestruturas, moradias e prédios públicos ou privados.
- **Prejuízos econômicos:** Perdas financeiras, interrupção de atividades e custos de resposta/recuperação nos setores público e privado.
- **Evento climático extremo:** Condições meteorológicas severas e fora do padrão habitual que podem provocar ou agravar desastres.

6.2. Estatísticas e Fatos

A ocorrência de desastres representa um problema relevante para o Brasil devido à frequência dos eventos extremos e à quantidade de pessoas e recursos afetados.

Essa dinâmica é impulsionada e influenciada por fenômenos climáticos globais como o El Niño — caracterizado pelo aquecimento anormal das águas do Oceano Pacífico Equatorial —, que altera os padrões de precipitação e temperatura em diversas regiões do país, elevando a ocorrência e a intensidade de secas e tempestades severas.

Um exemplo marcante da realidade dos desastres no país ocorreu no Rio Grande do Sul em 2024, quando fortes chuvas provocaram inundações, enxurradas, alagamentos e movimentos de massa em grande parte do estado. O desastre afetou 478 dos 497 municípios do Rio Grande do Sul, atingindo aproximadamente 2,4 milhões de pessoas. Além disso, foram registrados 183 óbitos, 27 desaparecidos, 18.864 feridos e enfermos, 121.878

desabrigados e 834.645 desalojados, evidenciando a dimensão dos impactos provocados pelo evento. O caso do Rio Grande do Sul demonstra que um único evento pode afetar uma parcela significativa da população e gerar consequências humanas, materiais e econômicas de grande proporção.

Dessa forma, a análise de dados históricos sobre desastres torna-se importante para compreender os padrões desses eventos e seus impactos, especialmente sobre a população.

6.3. Soluções Não-ml Existentes

Atualmente, uma das principais formas de acompanhamento dos desastres no Brasil ocorre por meio de sistemas de registro e consulta, como o S2iD e o Atlas Digital de Desastres. Essas plataformas permitem reunir informações históricas, consultar ocorrências por período, localização e tipo de desastre e analisar indicadores relacionados aos impactos dos eventos. Além desses sistemas, a análise dos dados pode ser realizada por meio de métodos estatísticos tradicionais, como médias, frequências, comparações históricas e análise de indicadores.

Essas abordagens são úteis para compreender o comportamento passado dos eventos, porém apresentam limitações quando o objetivo é identificar automaticamente relações mais complexas entre diferentes características dos desastres e seus impactos.

7. METODOLOGIA E DESENVOLVIMENTO

7.1. Modelos

Regressão Linear Múltipla

- **Tipo de Problema:** Regressão
- **Funcionamento e Fundamentos:** Trata-se de um modelo estatístico e de aprendizado de máquina supervisionado utilizado como linha de base (baseline). O algoritmo assume uma relação linear entre a variável dependente contínua (População_Afetada_Total transformada em escala logarítmica) e as múltiplas variáveis explicativas do dataset. Seus fundamentos baseiam-se em estimar coeficientes (pesos) ótimos para cada atributo de entrada por meio da minimização dos mínimos quadrados ordinários, traçando um hiperplano no espaço de características que melhor se ajusta aos dados histórico

K-Nearest Neighbors - KNN

- **Tipo de Problema:** Regressão.

- **Funcionamento e Fundamentos:** É um algoritmo de aprendizado supervisionado baseado em instâncias. O KNN não constrói um modelo matemático global fixo durante a fase de treinamento, mas armazena o espaço de características. O algoritmo calcula a distância entre o ponto de teste e seus vizinhos mais próximos utilizando métricas espaciais e pondera o resultado pela proximidade para calcular a média dos valores alvo dos vizinhos.

Random Forest Regressor

- **Tipo de Problema:** Regressão.
- **Funcionamento e Fundamentos:** Trata-se de uma técnica avançada de *ensemble* (aprendizado em conjunto) baseada no método de *bagging* (Bootstrap Aggregating). O algoritmo funciona construindo múltiplas árvores de decisão de forma independente e em paralelo. Cada árvore da floresta é alimentada por subconjuntos aleatórios dos dados originais (com reposição) e de características. A previsão final de regressão é obtida calculando a média aritmética das estimativas geradas por todas as árvores individuais.
- **Por que combinar modelos ajuda a melhorar o resultado:** Árvores de decisão isoladas tendem a apresentar alta variância e são altamente suscetíveis ao sobreajuste (*overfitting*), capturando ruídos específicos do conjunto de treinamento. A ideia central do *ensemble* por *bagging* é que, ao combinar dezenas ou centenas de árvores treinadas em perspectivas ligeiramente diferentes, os erros individuais de cada árvore se cancelam mutuamente. Isso reduz drasticamente a variância do modelo sem aumentar o viés, tornando a preposição final muito mais estável, robusta e capaz de mapear relações não lineares complexas presentes nos dados de desastres naturais.


7.2. Análise exploratória de dados (EDA)

Descrição Detalhada

- **Dimensões:** O conjunto de dados bruto possui 6.036 linhas (registros) e 53 colunas (atributos).
- **Tipos de Dados Principais:** object (6 colunas categóricas/texto), int64 (17 colunas de inteiros), float64 (30 colunas de ponto flutuante).

Diagnóstico do Dados

- **Valores Ausentes (NaN):** O dataset acumula um total geral de 25.896 valores nulos.
 - DA_Poluição do solo (5.578 nulos);
 - DA_Incêndios (5.437 nulos);
 - DA_Poluição da água (5.320 nulos);
 - DA_Poluição do ar (5.127 nulos);
 - DA_Exaurimento hídrico (4.315 nulos);
 - População (59 nulos);
 - DH_Outros Afetados (60 nulos).
- **Valores Extremos (Outliers):** População_Afetada_Total



Diagnóstico de Outliers

Boxplot (sns.boxplot): O gráfico ilustra a distribuição do número de pessoas afetadas pelos desastres. A forte concentração na base indica que a maioria dos registros refere-se a eventos de menor impacto, enquanto as bolinhas empilhadas (*outliers*) representam desastres de médio e grande porte, destacando no topo as raras mega-catástrofes que alcançam quase 3 milhões de afetados.

7.3. Pré-Processamento e Feature Engineering

Divisão dos dados

- **Proporção Utilizada:** O pipeline realiza uma divisão em duas etapas utilizando `train_test_split` com `random_state=42`:
 1. Separação inicial de 70% para Treino (`X_train`) e 30% temporário (`X_temp`).
 2. O conjunto temporário (`X_temp`) é dividido ao meio (50/50), resultando em 15% para Validação (`X_val`) e 15% para Teste (`X_test`).
- **Importância:** Garante a separação correta entre os dados de treinamento e teste, evitando vazamento de dados (data leakage) e avaliando de forma realista a capacidade de generalização dos modelos em dados inéditos.

Tratamento de nulo

- **Preenchimento por Zero (\$0\$):** Aplicado às variáveis numéricas de contagem de danos humanos (colunas `contagem`), sob a premissa de não ocorrência do dano respectivo.
- **Preenchimento pela Mediana:** Aplicado à variável População (fillna com a mediana das populações válidas), evitando distorções causadas por municípios de grande porte.
- **Preenchimento por Categoria Específica:** Substituição de nulos nas variáveis ambientais (colunas `ambientais` iniciadas por `DA_`) pela string 'Não Informado'.
- **Consistência Lógica:** Correção de registros inconsistentes onde o número de óbitos (`DH_Mortos`) superava a população total (População), limitando o valor de óbitos ao teto populacional.

Codificação Categórica

- **One-Hot Encoding (OneHotEncoder):** Aplicado no `ColumnTransformer` para todas as colunas de entrada do tipo texto/categóricas.

Normalização/Escalonamento

- **Normalização (StandardScaler):** Aplicado via `ColumnTransformer` em todas as colunas numéricas de entrada (`num_cols`), padronizando a escala das variáveis para otimizar o desempenho dos modelos (especialmente o KNN e a Regressão Linear).

- **RobustScaler:** Aplicado via ColumnTransformer em todas as colunas numéricas de entrada (num_cols). A escolha pelo RobustScaler substituiu o escalonamento tradicional para mitigar o impacto de valores atípicos severos (outliers comuns em dados de desastres naturais), utilizando a mediana e o intervalo interquartil, o que otimiza de forma mais estável o desempenho de modelos sensíveis a escala, como o KNN e a Regressão Linear.

Engenharia de Atributos

- **População_Afetada_Total:** Variável alvo da regressão, gerada pelo somatório de todas as colunas de impactos humanos individuais.
- **Estruturas Afetadas:** Criação de métricas consolidadas para estruturas danificadas (Total_Estruturas_Danificadas) e destruídas (Total_Estruturas_Destruidas).
- **Tipologia do Evento (Tipo_Evento):** Extraída e tratada diretamente a partir do código COBRADE.
- **Transformação Logarítmica:** Aplicação de np.log1p na variável alvo populacional para mitigar a assimetria severa e facilitar o aprendizado dos modelos.

7.4. Implementação, Treinamento e Otimização dos Modelos

Implementação

- A implementação dos modelos preditivos foi realizada em Python utilizando a biblioteca scikit-learn. O pipeline abrangeu o treinamento de três abordagens distintas: Regressão Linear Múltipla (baseline), KNN Regressor e Random Forest Regressor. Todos os modelos foram alimentados com os dados pré-processados via ColumnTransformer (incorporando o StandardScaler nas numéricas e o OneHotEncoder nas categóricas), sendo treinados no conjunto de treino e avaliados sobre os conjuntos de validação e teste.

Otimização

A otimização de hiperparâmetros foi conduzida de forma sistemática utilizando o GridSearchCV integrado com validação cruzada (cv=5 e métrica R^2):

- **Para o KNN Regressor**, a grade testou diferentes quantidades de vizinhos (n_neighbors: [3, 5, 7, 9, 11, 15]), tipos de ponderação (weights: ['distance']), métricas de distância (metric: ['manhattan',

'euclidean']) e algoritmos de busca (algorithm: ['auto', 'ball_tree']), selecionando automaticamente a melhor combinação.

- **Para o Random Forest Regressor**, o modelo passou por uma busca em grade robusta cobrindo o número de árvores (n_estimators: [100, 200, 300]), profundidade máxima (max_depth: [15, 25, None]), critérios de divisão e folha (min_samples_split e min_samples_leaf), além de diferentes frações de atributos por árvore (max_features: ['sqrt', 0.5]) para maximizar a capacidade de generalização e capturar relações não lineares complexas.

7.5. Avaliação e Análise Dos Resultados

Comparação quantitativa

=== TABELA DE MÉTRICAS COMPARAÇÃO ===

	Modelo de Regressão	MAE (Pessoas)	RMSE (Pessoas)	R ² (Escala Log)
0	Regressão Múltipla	32127.61	236709.60	0.5324
1	KNN Regressor (K=15)	8426.04	85732.99	0.6739
2	Random Forest Regressor	7940.55	70134.26	0.7592

Tabela de Métricas Antes da Otimização

=== TABELA COMPARATIVA DE MÉTRICAS ===

	Modelo de Regressão	MAE (Pessoas)	RMSE (Pessoas)	R ² (Escala Log)
0	Regressão Múltipla	30861.52	227150.82	0.5130
1	KNN Regressor (K=15)	7660.81	65692.43	0.6750
2	Random Forest Regressor	9686.21	94839.79	0.7591

Tabela de Métricas Depois da Otimização

Justificativa Das Métricas

- **MAE (Erro Absoluto Médio - Mean Absolute Error):** Mede a magnitude média dos erros absolutos entre a população afetada prevista e a real (em número de pessoas), sem penalizar excessivamente os desvios extremos. É fundamental para dar uma perspectiva prática e direta do erro operacional para a Defesa Civil.
- **RMSE (Raiz do Erro Quadrático Médio - Root Mean Squared Error):** Eleva os erros ao quadrado antes de tirar a média, o que

penaliza de forma severa os grandes erros de predição. É crucial neste problema devido à presença de desastres de grande escala (superdesastres), onde errar a estimativa de um evento extremo tem um custo logístico elevado.

- **Coefficiente de Determinação (R^2):** Avalia a proporção da variabilidade da variável alvo que é explicada pelo modelo, permitindo mensurar o quão bem o aprendizado de máquina se ajustou aos dados históricos em comparação a uma média simples.

Visualizações

- **Gráficos de Dispersão (Previsão vs. Valor Real em Escala Log):** Exibidos lado a lado para a Regressão Múltipla, KNN e Random Forest, traçando a linha de referência ideal para evidenciar o alinhamento das previsões.




Gráfico de Dispersão Antes da Otimização

Análise dos Resultados:

A Regressão Múltipla teve o pior desempenho ($R^2 = 0,5324$; MAE = 32.127,61; RMSE = 236.709,60), com o seu gráfico de dispersão a mostrar uma forte dispersão vertical dos pontos em torno da linha ideal, evidenciando que modelos lineares falham em capturar a complexidade dos dados.

O KNN ($K = 15$) apresentou uma melhoria clara ($R^2 = 0,6739$; MAE = 8.426,04; RMSE = 85.732,99), refletida no seu gráfico por um alinhamento superior dos pontos ao longo da diagonal vermelha, embora ainda exiba alguma dispersão nas extremidades.

O Random Forest foi o melhor modelo ($R^2 = 0,7592$; MAE = 7.940,55; RMSE = 70.134,26), apresentando no seu gráfico a maior concentração de pontos colados à linha de previsão perfeita, o que confirma visualmente a sua elevada precisão para estimar a população afetada.




Gráfico de Dispersão Depois da Otimização


Análise dos Resultados:

Regressão Múltipla ($R^2 = 0,5130$; MAE = 30.861,52; RMSE = 227.150,82): Continua a ser o pior modelo, com uma dispersão vertical enorme e aquela linha vertical de previsões truncadas no zero.

KNN Regressor ($R^2 = 0,6750$; MAE = 7.660,81; RMSE = 65.692,43): Apresentou erros médios menores e um R^2 superior à Regressão Múltipla. O gráfico mostra os pontos mais concentrados ao longo da diagonal.

Random Forest Regressor ($R^2 = 0,7591$; MAE = 9.686,21; RMSE = 94.839,79): Teve o melhor R^2 geral (75,91%), o que significa que explica melhor a variabilidade global dos dados. No entanto, curiosamente, o seu MAE e RMSE absolutos em pessoas ficaram um pouco acima do KNN nesta execução específica. Visualmente, o gráfico de dispersão verde mostra uma densidade forte acompanhando a linha vermelha, mas com dispersão nos extremos.

- **Histograma de Resíduos:** Gráfico da distribuição dos erros (resíduos em escala log) comparados à linha de erro zero, permitindo identificar tendências de superestimação ou subestimação dos modelos.




Histograma de Resíduos

Análise dos Resultados:

O histograma mostra que os erros de predição em escala logarítmica estão concentrados fortemente ao redor da linha de **Erro Zero**, com o pico máximo superando 350 desastres na barra central. O formato em sino da curva de densidade confirma uma distribuição aproximadamente normal e bem equilibrada, demonstrando que o modelo não possui um vício sistemático de superestimar ou subestimar o impacto dos eventos. Por fim, as caudas mais suaves nas extremidades refletem apenas erros pontuais em desastres de magnitudes atípicas, o que justifica a diferença esperada entre as métricas de erro do modelo.

- **Mapa de Calor da Matriz de Confusão:** Ilustra o desempenho da categorização dos níveis de risco (*Baixo*, *Médio* e *Alto*) obtidos a partir das premissas de corte da população afetada.




Matriz de Confusão do Nível de Risco

Análise dos Resultados:

A Matriz de Confusão do Nível de Risco mostra uma forte concentração de acertos na diagonal principal, com o modelo a classificar corretamente a grande maioria dos eventos de risco Baixo (431 casos de 469) e obtendo um bom desempenho na categoria de risco Médio (148 acertos). Nos erros observados, nota-se que o modelo é conservador nas transições extremas, registrando raríssimas confusões graves entre os níveis opostos (apenas 9 eventos de risco Baixo foram classificados como Alto, e 22 de risco Alto como Baixo). A maior parte dos desvios ocorre entre categorias adjacentes (como 106 casos de risco Alto classificados como Médio), o que confirma a boa capacidade do Random Forest em capturar a gradação real de gravidade dos desastres.

- **Variáveis Mais Importantes (Interpretabilidade do Random Forest):**

Para além das métricas de erro, analisou-se o gráfico de importância relativa gerado pelo Random Forest Regressor, visando compreender quais fatores mais influenciam a estimativa da população afetada.



Variáveis Mais Importantes

Análise dos Resultados:

O gráfico evidencia que variáveis ambientais específicas (como dados de exaurimento hídrico), gastos com abastecimento de água potável e obras de infraestrutura pública, além de tipologias de eventos como tempestades locais/convectivas e o porte populacional, detêm o maior poder preditivo. Isso demonstra coerência lógica com a realidade operacional de desastres, onde a magnitude do impacto humano está fortemente correlacionada com a vulnerabilidade ambiental e os danos estruturais/financeiros mitigados.

Análise Crítica

O melhor modelo para o problema foi o Random Forest Regressor, que superou a Regressão Múltipla e o KNN por sua capacidade superior de capturar interações complexas e não lineares entre as variáveis ambientais e estruturais. Enquanto modelos lineares sofrem com premissas rígidas e o KNN enfrenta limitações na alta dimensionalidade, a abordagem de ensemble mitigou o impacto de desastres extremos e reduziu a variância dos erros de forma consistente. Embora essa alta performance acarrete uma redução na interpretabilidade matemática direta, o ganho expressivo de precisão preditiva compensa essa perda, entregando uma solução robusta e altamente confiável para otimizar o planejamento e a alocação de recursos da Defesa Civil.

8. INTERFACE

A interface interativa do projeto foi desenvolvida para possibilitar simulações em tempo real de estimativa de população afetada e nível de risco em eventos climáticos. Organizada em seções claras, a ferramenta permite ao usuário inserir dados contextuais sobre a localização e tipo de evento (como UF, população total e codificação COBRADE) e os danos materiais informados (unidades habitacionais danificadas, destruídas e obras de infraestrutura).

Ao acionar a geração de estimativas, a aplicação exibe painéis comparativos lado a lado com os resultados do KNN Regressor e do Random Forest Regressor, apresentando o total absoluto de pessoas estimadas, a porcentagem da população atingida, a classificação do risco (Baixo, Médio ou Alto) e a variação entre os modelos. Conforme ilustrado na imagem anexa abaixo, essa estrutura intuitiva facilita a análise preditiva e apoia a tomada de decisão em gestão de desastres.

1. Localização e Evento

Unidade Federativa (UF): PR

População Total do Município: 23425

Tipo do Evento Climático (COBRADE): Inundações

2. Danos Materiais Informados

Unidades Habitacionais Danificadas: 78

Unidades Habitacionais Destruidas: 0

Obras de Infraestrutura Pública Destruidas/Danificadas: 13

Gerar Estimativas Comparativas


Previsão de População Afetada e Nível de Risco

KNN REGRESSOR	RANDOM FOREST REGRESSOR	DIFERENÇA ABSOLUTA
103 Pessoas estimadas	78 Pessoas estimadas	25 Variação entre os modelos
0.44% da população	0.33% da população	Cortes históricos: Baixo (<3.6%) Médio (3.6%-50.2%) Alto (>50.2%)
Risco Baixo	Risco Baixo	

Interface dos Modelos

9. GITHUB

O repositório público no GitHub, intitulado `Classificacao-eventos-climaticos` (disponível em github.com/LaraDondossola/Classificacao-eventos-climaticos), centraliza todo o código-fonte, dados e documentação do projeto de Machine Learning voltado à análise de riscos de desastres ambientais. Organizado de forma estruturada, o repositório conta com diretórios dedicados para os Datasets, Notebooks e modelos treinados (Models), além de um arquivo `README.md` completo que detalha os objetivos, o fluxo das etapas desenvolvidas e as orientações de uso. Conforme ilustrado na imagem anexa abaixo, essa estrutura garante a transparência, reprodutibilidade dos experimentos e a versionação colaborativa das soluções de regressão e classificação do projeto.



Repositório no Github

10. CONCLUSÃO

O presente trabalho demonstrou o potencial da aplicação de técnicas de Aprendizagem Automática (Machine Learning) no domínio de gestão de riscos e desastres, com foco no suporte à atuação da Defesa Civil. A partir da utilização de dados oficiais do S2iD referentes ao ano de 2024, foi possível estruturar um pipeline completo que abrangeu desde a análise exploratória e o tratamento rigoroso de valores ausentes e outliers até a engenharia de atributos e a modelagem preditiva.

A implementação e a otimização de três abordagens de Machine Learning Clássico — Regressão Linear Múltipla, K-Nearest Neighbors (KNN) e Random Forest Regressor — permitiram avaliar o comportamento dos dados diante de diferentes níveis de complexidade. Os resultados quantitativos evidenciaram que o Random Forest Regressor obteve o melhor desempenho preditivo, superando os demais modelos ao capturar de forma eficaz as relações não lineares entre as variáveis ambientais, estruturais e a população afetada. A combinação de bagging e árvores de decisão atenuou os impactos de desastres extremos (superdesastres) e reduziu a variância dos erros, confirmando a robustez da abordagem de ensemble.

Além disso, a integração da regressão com a categorização dos níveis de risco proporcionou uma visão operacional clara, facilitando a interpretação prática dos impactos para o planejamento logístico. Embora o estudo apresente limitações inerentes à variabilidade e à presença de dados ausentes em bases de registros oficiais, a ferramenta desenvolvida cumpre o objetivo de transformar grandes volumes de dados históricos em previsões ágeis e estruturadas.

11. REFERÊNCIAS

- BRASIL. Ministério da Integração e do Desenvolvimento Regional. S2iD: Sistema Integrado de Informações sobre Desastres. Relatórios de ocorrências. Disponível em: <https://s2id.mi.gov.br/paginas/relatorios/>. Acesso em: 25 set. 2026.
- CLIMAINFO. O que é o El Niño? Disponível em: <https://climainfo.org.br/duvidas-do-clima/o-que-e-o-el-nino/>. Acesso em: 27 set. 2026.
- CNN BRASIL. Enchentes de 2024 no RS afetaram mais de 6 milhões de pessoas, estima IBGE. Nacional, 2024. Disponível em: <https://www.cnnbrasil.com.br/nacional/sul/rs/enchentes-de-2024-no-rs-afetaram-mais-de-6-milhoes-de-pessoas-estima-ibge/>. Acesso em: 25 set. 2026.
- IGLESIAS, Jordi et al. Predictive modeling of severe weather impact on individuals and populations using Machine Learning. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2212420924001602?via%3Dihub>. Acesso em: 27 set. 2026.